

# Βέλτιστη Εκτίμηση Κατάστασης

II. Μη γραμμικά Φίλτρα

# Υποθέσεις Φίλτρου Kalman

- Σύστημα είναι γραμμικό
- Οι θόρυβοι και οι διαταραχές έχουν κανονική κατανομή
- Η αρχική κατάσταση κατανέμεται κανονικά

Αν ισχύουν όλα αυτά τότε η posterior κατανομή του  $x_k$  δοσμένων των μετρήσεων **είναι** κανονική με γνωστή μέση τιμή και συν-διακύμανση

$$x_k | y_{0:k} \sim N(\hat{x}_k, P_{x_k})$$

Όταν δεν ισχύουν οι υποθέσεις .. θα δουλέψουμε **προσεγγιστικά**

# Περιεχόμενα

Extended Kalman Filter (EKF)

Unscented Kalman Filter

Particle Filter

## Extended Kalman Filter (EKF)

# Extended Kalman Filter (EKF)

Ελαφρά μη-γραμμικά συστήματα

$$x_{k+1} = f(x_k, u_k) + w_k$$

$$y_k = h(x_k) + v_k$$

**Στόχος:** Εκτίμηση της κατάστασης δοσμένων των μετρήσεων

**Υπόθεση:** Στο βήμα  $k$  η κατανομή της κατάστασης  $x_k$  δοσμένων των μετρήσεων  $y_0, \dots, y_k$  είναι Gaussian

$$x_k \mid y_{0:k} \sim N(\hat{x}_k, P_{x_k})$$

# Extended Kalman Filter (EKF)

Ελαφρά μη-γραμμικά συστήματα

$$x_{k+1} = f(x_k, u_k) + w_k$$

$$y_k = h(x_k) + v_k$$

**Στόχος:** Εκτίμηση της κατάστασης δοσμένων των μετρήσεων

**Υπόθεση:** Στο βήμα  $k$  η κατανομή της κατάστασης  $x_k$  δοσμένων των μετρήσεων  $y_0, \dots, y_k$  είναι Gaussian

$$x_k \mid y_{0:k} \sim N(\hat{x}_k, P_{x_k})$$

**Ιδέα:** Θα προσεγγίσουμε το  $x_{k+1} \mid y_0, \dots, y_{k+1}$  σαν να ήταν Gaussian

# Extended Kalman Filter (EKF)

**Prediction Step:** Προσεγγίζουμε την  $x_{k+1} | y_{0:k}$  από μια κανονική κατανομή

$$x_{k+1} | y_{0:k} \sim N\left(f(\hat{x}_k, u_k), P_{x_{k+1}}^-\right) \quad x_{k+1}^- = f(\hat{x}_k, u_k)$$

Η αναμενόμενη τιμή είναι ο μη γραμμικός μετασχηματισμός του  $\hat{x}_k$

Η συν-διακύμανση?

# Extended Kalman Filter (EKF)

**Prediction Step:** Προσεγγίζουμε την  $x_{k+1} | y_{0:k}$  από μια κανονική κατανομή

$$x_{k+1} | y_{0:k} \sim N\left(f(\hat{x}_k, u_k), P_{x_{k+1}}^-\right) \quad x_{k+1}^- = f(\hat{x}_k, u_k)$$

Η αναμενόμενη τιμή είναι ο μη γραμμικός μετασχηματισμός του

Η συν-διακύμανση? Κοντά στο μέσο η  $f$  είναι **προσεγγιστικά γραμμική**

$$f(x, u) \simeq f(\hat{x}, u) + \left. \frac{\partial f}{\partial x} \right|_{(\hat{x}, u)} (x - \hat{x}) = f(\hat{x}, u) + A_k (x - \hat{x})$$

→ Jacobian

Έτσι **προσεγγιστικά** η συν-διακύμανση γίνεται

$$P_{x_{k+1}}^- = A_k P_{x_k} A_k^T + Q$$



# Extended Kalman Filter (EKF)

## Correction step

$$y_{k+1}^- = h(x_{k+1}^-) = h(f(\hat{x}_k, u_k))$$

$$C_{k+1} = \left. \frac{\partial h}{\partial x} \right|_{\hat{x}_{k+1}^-}$$

$$P_{y_{k+1}^-} = C_{k+1} P_{x_{k+1}^-} C_{k+1}^T + R$$

$$P_{x_{k+1}y_{k+1}}^- = P_{x_{k+1}}^- C_{k+1}^T.$$

$$x_{k+1}^- = f(\hat{x}_k, u_k)$$

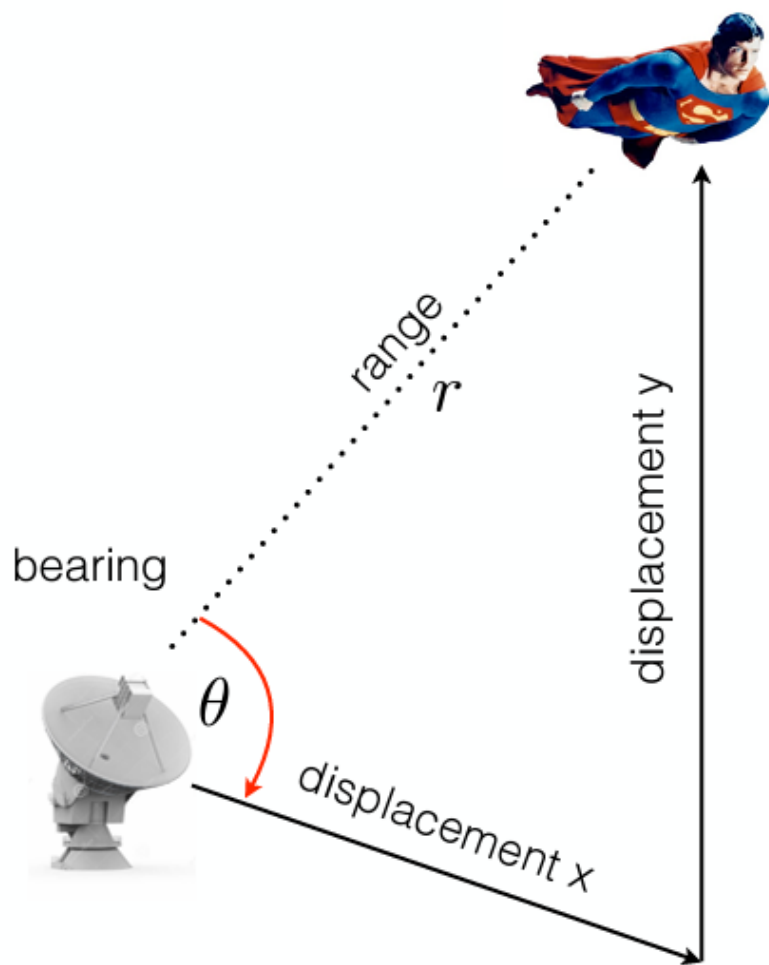
$$K_{k+1} = P_{x_{k+1}y_{k+1}}^- P_{y_{k+1}}^{-1}.$$

$$\hat{x}_{k+1} = \hat{x}_{k+1}^- + K_{k+1} (y_{k+1} - \hat{y}_{k+1}^-),$$

$$P_{x_{k+1}} = P_{x_{k+1}}^- - K_{k+1} P_{y_{k+1}}^- K_{k+1}^T.$$

Όπως πριν !

Παράδειγμα από <https://www.cs.cmu.edu/~16385/s17/>



**state:** position-velocity

$$\mathbf{x} = \begin{bmatrix} x \\ \dot{x} \\ y \\ \dot{y} \end{bmatrix} \begin{array}{l} \text{position} \\ \text{velocity} \\ \text{position} \\ \text{velocity} \end{array}$$


constant velocity motion model

$$A = \begin{bmatrix} 1 & \Delta t & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & \Delta t \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

with additive Gaussian noise

Slides from  
<https://www.cs.cmu.edu/~16385/s17/>

Motion model is linear but ...



**measurement:** range-bearing

$$\begin{aligned} z &= \begin{bmatrix} r \\ \theta \end{bmatrix} \\ &= \begin{bmatrix} \sqrt{x^2 + y^2} \\ \tan^{-1}(y/x) \end{bmatrix} \end{aligned}$$

measurement model

*Is the measurement model linear?*

$$z = h(r, \theta)$$

with additive Gaussian noise

**linearize** the observation/measurement model!

$$\begin{aligned} \mathbf{z} &= \begin{bmatrix} r \\ \theta \end{bmatrix} \\ &= \begin{bmatrix} \sqrt{x^2 + y^2} \\ \tan^{-1}(y/x) \end{bmatrix} \end{aligned}$$

$$H = \frac{\partial \mathbf{z}}{\partial \mathbf{x}} = ?$$

*What is the Jacobian?*

$$H = \begin{bmatrix} \frac{\partial r}{\partial x} & \frac{\partial r}{\partial \dot{x}} & \frac{\partial r}{\partial y} & \frac{\partial r}{\partial \dot{y}} \\ \frac{\partial \theta}{\partial x} & \frac{\partial \theta}{\partial \dot{x}} & \frac{\partial \theta}{\partial y} & \frac{\partial \theta}{\partial \dot{y}} \end{bmatrix} = \begin{bmatrix} \cos(\theta) & 0 & \sin(\theta) & 0 \\ -\sin(\theta)/r & 0 & \cos(\theta)/r & 0 \end{bmatrix}$$

Slides from  
<https://www.cs.cmu.edu/~16385/s17/>

# Παράδειγμα: Sensor Fusion

Ρομπότ με δύο ρόδες

Εξισώσεις κατάστασης



$$\begin{bmatrix} x_{k+1} \\ y_{k+1} \\ \theta_{k+1} \end{bmatrix} = \begin{bmatrix} x_k + \delta t \cdot v_k \cos \theta_k \\ y_k + \delta t \cdot v_k \sin \theta_k \\ \theta_k + \delta t \cdot \alpha (v_k^r - v_k^l) \end{bmatrix} + \begin{bmatrix} w_k^1 \\ w_k^2 \\ w_k^3 \end{bmatrix},$$

$$v_k = \frac{v_k^l + v_k^r}{2}$$

Γιατί μπορεί να έχω διαταραχές;

Πιθανοί αισθητήρες

- Odometry
- Inertial measurement unit
- GPS
- Optical

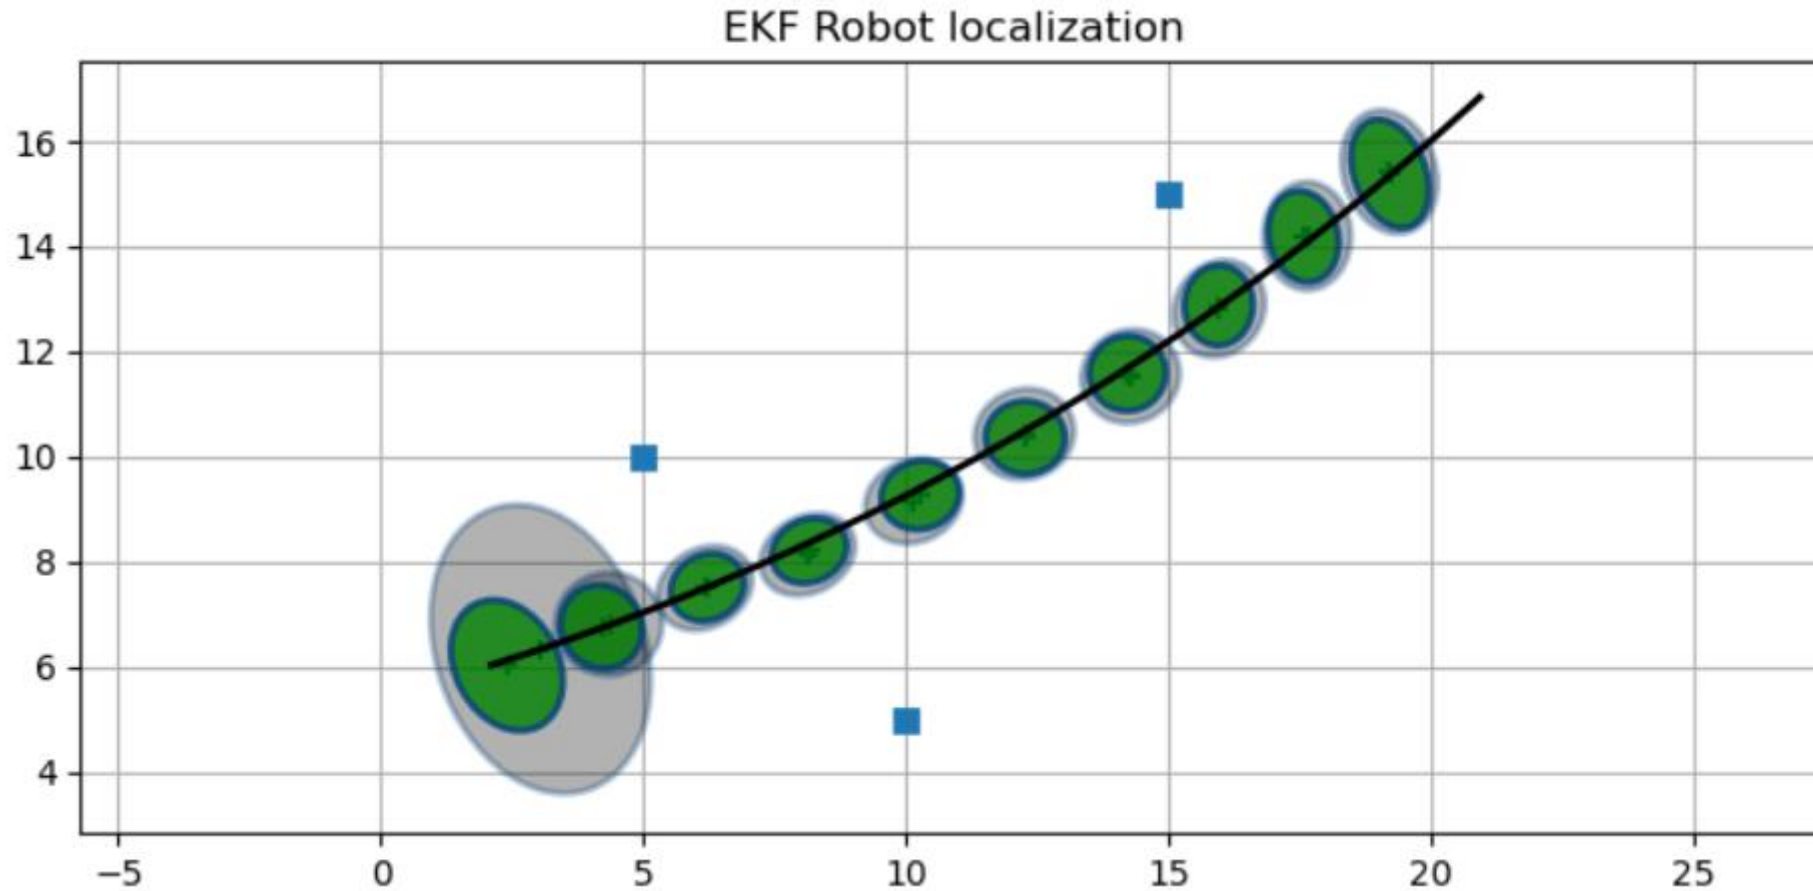


# Example: Sensor Fusion

Γραμμικοποίηση

$$A_k = \begin{bmatrix} 1 & 0 & \delta t \cdot v_k \cos \hat{\theta}_k \\ 0 & 1 & \delta t \cdot v_k \sin \hat{\theta}_k \\ 0 & 0 & 1 \end{bmatrix}$$

# Παράδειγμα ΕΚΦ





# Sigma Point Filters


# Μετασχηματισμός μιας Gaussian

Αν η  $f$  είναι πολύ μη γραμμική τότε η κατανομή του  $f(x)$  δεν είναι κοντά σε κανονική

Παράδειγμα  $f(x) = \exp(x)$ .

Το **μέσο** δεν απεικονίζεται κοντά στο **μέσο** !

$$\exp[E[Y]] \neq E[\exp(Y)]$$



# Sigma Point Kalman Filters

## Πρόβλημα EKF

Ακόμα κι αν τα  $x_k$  και  $w_k$  είναι gaussian, η επόμενη κατάσταση  $f(x_k) + w_k$  δεν είναι.

Θα την προσεγγίσουμε με gaussian

Ποια είναι τα στατιστικά χαρακτηριστικά της;

# Sigma Point Kalman Filters

## Πρόβλημα EKF

Ακόμα κι αν τα  $x_k$  και  $w_k$  είναι gaussian, η επόμενη κατάσταση  $f(x_k) + w_k$  δεν είναι.

Αν έχουμε έντονη μη γραμμικότητα τα **χαρακτηριστικά** που υπολογίζουμε για την  $f(x_k) + w_k$  με τη γραμμικοποίηση δεν είναι σωστά!

# Sigma Point Kalman Filters

## Πρόβλημα EKF

Ακόμα κι αν τα  $x_k$  και  $w_k$  είναι gaussian, η επόμενη κατάσταση  $f(x_k) + w_k$  δεν είναι.

Ποια είναι τα στατιστικά χαρακτηριστικά της; Μέσος και Συν-δικύμανση;

## A-priori mean

$$\hat{x}_{k+1}^- = E[x_{k+1} | y_{0:k}] = E[f(x_k) | y_{0:k}]$$

$$x_{k+1} = f(x_k, u_k) + w_k$$

$$y_k = h(x_k) + v_k$$

## A-priori covariance

$$P_{x_{k+1}}^- = E\left[(x_{k+1} - \hat{x}_{k+1}^-)(x_{k+1} - \hat{x}_{k+1}^-)^T | y_{0:k}\right]$$

$$= E\left[(f(x_k) + w_k - \hat{x}_{k+1}^-)(f(x_k) + w_k - \hat{x}_{k+1}^-)^T | y_{0:k}\right] = E\left[f(x_k)f(x_k)^T | y_{0:k}\right] - \hat{x}_{k+1}^- (\hat{x}_{k+1}^-)^T + Q$$

# Sigma Point Kalman Filters

## Πρόβλημα EKF

Ακόμα κι αν τα  $x_k$  και  $w_k$  είναι gaussian, η επόμενη κατάσταση  $f(x_k) + w_k$  δεν είναι.  
Ποια είναι τα στατιστικά χαρακτηριστικά της;

## A-priori mean

$$\hat{x}_{k+1}^- = E[x_{k+1} | y_{0:k}] = E[f(x_k) | y_{0:k}] \longrightarrow E[g(X)]: X \text{ approximately Gaussian}$$

## A-priori covariance

$$\begin{aligned} P_{x_{k+1}}^- &= E\left[(x_{k+1} - \hat{x}_{k+1}^-)(x_{k+1} - \hat{x}_{k+1}^-)^T | y_{0:k}\right] \\ &= E\left[(f(x_k) + w_k - \hat{x}_{k+1}^-)(f(x_k) + w_k - \hat{x}_{k+1}^-)^T | y_{0:k}\right] = \underbrace{E\left[f(x_k) f(x_k)^T | y_{0:k}\right]}_{\substack{\uparrow \\ E[g(X)]}} - \hat{x}_{k+1}^- (\hat{x}_{k+1}^-)^T + Q \end{aligned}$$

# Sigma Point Kalman Filters

Παρόμοια, για τα  $P_{y_{k+1}^-}$ ,  $P_{x_{k+1}, y_{k+1}}$  θα χρειαστεί να υπολογίσουμε

$$E[g(X)]: X \sim N(\mu, \Sigma)$$

# Sigma Point Kalman Filters

Παρόμοια, για τα  $P_{y_{k+1}^-}$ ,  $P_{x_{k+1}, y_{k+1}}$  θα χρειαστεί να υπολογίσουμε

$$E[g(X)]: X \sim N(\mu, \Sigma)$$

Πώς θα υπολογίσουμε ολοκληρώματα στη μορφή

$$E[g(X)] = \frac{1}{C} \int g(x) \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) dx$$



# Sigma Point Kalman Filters


Παρόμοια, για τα  $P_{y_{k+1}^-}$ ,  $P_{x_{k+1}, y_{k+1}}$  θα χρειαστεί να υπολογίσουμε

$$E[g(X)]: X \sim N(\mu, \Sigma)$$

Πώς θα υπολογίσουμε **ολοκληρώματα** στη μορφή

$$E[g(X)] = \frac{1}{C} \int g(x) \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) dx$$

Σε χαμηλή διάσταση μπορούμε να χρησιμοποιήσουμε **αριθμητική ολοκλήρωση** (π.χ. κανόνα τραπεζίου), αλλά..



# Sigma Point Kalman Filters

Παρόμοια, για τα  $P_{y_{k+1}^-}$ ,  $P_{x_{k+1}, y_{k+1}}$  θα χρειαστεί να υπολογίσουμε

$$E[g(X)]: X \sim N(\mu, \Sigma)$$

Πώς θα υπολογίσουμε **ολοκληρώματα** στη μορφή

$$E[g(X)] = \frac{1}{C} \int g(x) \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) dx$$

Σε χαμηλή διάσταση μπορούμε να χρησιμοποιήσουμε **αριθμητική ολοκλήρωση** (π.χ. κανόνα τραπεζίου), αλλά..

Σε υψηλότερη διάσταση **προσέγγιση με σ-points**

$$E[g(X)] \approx \sum_{i=1}^l W_i g(\chi_i): \quad \chi_i: \text{samples} \quad W_i: \text{weights},$$

# Προσεγγιστική Ολοκλήρωση με σ-Points

Για το ολοκλήρωμα

$$E[g(X)] = \frac{1}{C} \int g(x) \exp\left(-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)\right) dx$$


Ο  $\Sigma$  είναι θετικά ορισμένος. Άρα υπάρχει πίνακας  $S$  έτσι ώστε  $\Sigma = SS^T$

$$\xi \sim N(0, I) \Rightarrow \mu + S\xi \sim N(\mu, SIS^T) = N(\mu, \Sigma)$$

συμβολίζουμε  $S = \Sigma^{1/2}$

Έτσι αρκεί να υπολογίσουμε

$$E[g(\mu + S\xi)] = \frac{1}{C} \int g(\mu + S\xi) \exp\left(-\frac{\|\xi\|^2}{2}\right) d\xi$$






Cholesky  
Decomposition

# Προσεγγιστική Ολοκλήρωση με σ-Points: Παράδειγμα

Θέλουμε να υπολογίσουμε

$$E[Y], \text{ where } Y = g(X)$$

Illustration from  
[Hammarstrand's lectures](#)



$$E[g(X)] \approx \sum_{i=1}^l W_i g(\chi_i):$$

$\chi_i$  : samples     $W_i$ : weights,

$$E[g(\mu + S\xi)] = \frac{1}{C} \int g(\mu + S\xi) \exp\left(-\frac{\|\xi\|^2}{2}\right) d\xi$$

# Προσεγγιστική Ολοκλήρωση με σ-Points

Unscented Transformation:

$$E[g(X)] \approx \sum_{i=1}^l W_i g(\chi_i): \quad \chi_i : \text{samples} \quad W_i : \text{weights},$$

Όπου

$$\chi_0 = \mu$$

$$\chi_i = \mu + \sqrt{\frac{n}{1-W_0}} S_i, \quad i = 1, \dots, n$$

$$\chi_i = \mu - \sqrt{\frac{n}{1-W_0}} S_i, \quad i = n+1, \dots, 2n$$

$$S = \sqrt{\Sigma} \\ (\Sigma = SS^T)$$

$$\sum_{i=1}^{2n+1} W_i \delta_{\chi_i}$$

$$W_0$$

$$W_i = \frac{1-W_0}{2n}$$

# Unscented Transformation: Illustration

## UT for polar measurements

- Consider again the example where

$$\mathbf{y} = \mathbf{g}(\mathbf{x}) = \begin{bmatrix} \sqrt{x_1^2 + x_2^2} \\ \arctan\left(\frac{x_2}{x_1}\right) \end{bmatrix}$$

and

$$\mathbf{x} \sim \mathcal{N}\left(\begin{bmatrix} 2 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & -1.8 \\ -1.8 & 2 \end{bmatrix}\right)$$




Illustration from  
[Hammarstrand's lectures](#)

# Unscented Kalman Filter

## PREDICTION IN UKF

---

1. Form a set of  $2n + 1$   $\sigma$ -points

$$\mathcal{X}_{k-1}^{(0)} = \hat{\mathbf{x}}_{k-1|k-1},$$

$$\mathcal{X}_{k-1}^{(i)} = \hat{\mathbf{x}}_{k-1|k-1} + \sqrt{\frac{n}{1 - W_0}} \left( \mathbf{P}_{k-1|k-1}^{1/2} \right)_i, \quad i = 1, 2, \dots, n,$$

$$\mathcal{X}_{k-1}^{(i+n)} = \hat{\mathbf{x}}_{k-1|k-1} - \sqrt{\frac{n}{1 - W_0}} \left( \mathbf{P}_{k-1|k-1}^{1/2} \right)_i, \quad i = 1, 2, \dots, n,$$

$$W_i = \frac{1 - W_0}{2n}, \quad i = 1, 2, \dots, 2n.$$

2. Compute the predicted moments

$$\hat{\mathbf{x}}_{k|k-1} \approx \sum_{i=0}^{2n} \mathbf{f}(\mathcal{X}_{k-1}^{(i)}) W_i$$

$$\mathbf{P}_{k|k-1} \approx \mathbf{Q}_{k-1} + \sum_{i=0}^{2n} (\mathbf{f}(\mathcal{X}_{k-1}^{(i)}) - \hat{\mathbf{x}}_{k|k-1})(\cdot)^T W_i$$

# Unscented Kalman Filter

## UPDATE IN UKF

---

1. Form a set of  $2n + 1$   $\sigma$ -points

$$\mathcal{X}_k^{(0)} = \hat{\mathbf{x}}_{k|k-1}, \quad W_i = \frac{1 - W_0}{2n}, \quad i > 1,$$

$$\mathcal{X}_k^{(i)} = \hat{\mathbf{x}}_{k|k-1} + \sqrt{\frac{n}{1 - W_0}} \left( \mathbf{P}_{k|k-1}^{1/2} \right)_i, \quad i = 1, 2, \dots, n,$$

$$\mathcal{X}_k^{(i+n)} = \hat{\mathbf{x}}_{k|k-1} - \sqrt{\frac{n}{1 - W_0}} \left( \mathbf{P}_{k|k-1}^{1/2} \right)_i, \quad i = 1, 2, \dots, n,$$

2. Compute the desired moments

$$\hat{\mathbf{y}}_{k|k-1} \approx \sum_{i=0}^{2n} \mathbf{h}(\mathcal{X}_k^{(i)}) W_i$$

$$\mathbf{P}_{xy} \approx \sum_{i=0}^{2n} \left( \mathcal{X}_k^{(i)} - \hat{\mathbf{x}}_{k|k-1} \right) \left( \mathbf{h}(\mathcal{X}_k^{(i)}) - \hat{\mathbf{y}}_{k|k-1} \right)^T W_i$$

$$\mathbf{S}_k \approx \mathbf{R}_k + \sum_{i=0}^{2n} \left( \mathbf{h}(\mathcal{X}_k^{(i)}) - \hat{\mathbf{y}}_{k|k-1} \right) (\cdot)^T W_i$$

$$\begin{cases} \hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{P}_{xy} \mathbf{S}_k^{-1} (\mathbf{y}_k - \hat{\mathbf{y}}_{k|k-1}) \\ \mathbf{P}_{k|k} = \mathbf{P}_{k|k-1} - \mathbf{P}_{xy} \mathbf{S}_k^{-1} \mathbf{P}_{xy}^T. \end{cases}$$



# Άλλες Τεχνικές

- Cubature:

$$W_0=0$$

- Gauss Hermite: Πολλά σημεία σε κάθε διάσταση

Εκτίμηση Κατάστασης σε Hidden Markov Models


# The Filtering Problem for Hidden Markov Models

Σύστημα με διακριτό χώρο κατάστασης (HMM)

$$x_{k+1} = f(x_k, w_k)$$

$$y_k = h(x_k, v_k)$$

- Το  $x_k$  μπορεί να πάρει ένα πεπερασμένο σύνολο από τιμές  $\{1, \dots, m\}$
- Ονομάζεται **Αλυσίδα Markov**
- Το  $y_k$  μπορεί να πάρει είτε συνεχείς η διακριτές τιμές



# The Filtering Problem for Hidden Markov Models

Σύστημα με διακριτό χώρο κατάστασης (HMM)

$$x_{k+1} = f(x_k, w_k)$$

$$y_k = h(x_k, v_k)$$

- Για κάθε  $x_k$  υπάρχει μια σ.μ.π

$$\begin{aligned} P(x_{k+1} = j \mid y_0, \dots, y_k) &= \sum_{i=1}^m P(x_{k+1} = j \mid x_k = i, y_0, \dots, y_k) P(x_k = i \mid y_0, \dots, y_k) \\ &= \sum_{i=1}^m P(x_{k+1} = j \mid x_k = i) P(x_k = i \mid y_0, \dots, y_k) \end{aligned}$$

# The Filtering Problem for Hidden Markov Models

Σύστημα με διακριτό χώρο κατάστασης (HMM)

$$x_{k+1} = f(x_k, w_k)$$

$$y_k = h(x_k, v_k)$$

- Όταν μετρήσουμε το  $y_{k+1}$  η εκ των υστέρων εκτίμηση του  $x_{k+1}$ , γίνεται


$$\begin{aligned} P(x_{k+1} = j | y_0, \dots, y_{k+1}) &= \frac{P(y_{k+1} | x_{k+1} = j, y_0, \dots, y_k) P(x_{k+1} = j | y_0, \dots, y_k)}{\sum_{i=1}^m P(y_{k+1} | x_{k+1} = i, y_0, \dots, y_k) P(x_{k+1} = i | y_0, \dots, y_k)} \\ &= \frac{P(y_{k+1} | x_{k+1} = j) P(x_{k+1} = j | y_0, \dots, y_k)}{\sum_{i=1}^m P(y_{k+1} | x_{k+1} = i) P(x_{k+1} = i | y_0, \dots, y_k)} \end{aligned}$$

# Παράδειγμα

Μια μηχανή παράγει αντιστάτες με ονομαστική αντίσταση  $R$

Η μηχανή μπορεί να είναι σε μια από δύο καταστάσεις Proper (P) και non-proper (P')

- Αν η μηχανή είναι στην κατάσταση  $R$  οι αντιστάτες που παράγει έχουν αντίσταση από με κατανομή  $N(R, \sigma_1)$ ,
- Αλλιώς η κατανομή είναι  $N(R, \sigma_2)$ , με  $\sigma_2 > \sigma_1$ .



# Παράδειγμα

Η κατάσταση εξελίσσεται σύμφωνα με τη **στοχαστική δυναμική**

$$P(x_{k+1} = P \mid x_k = P) = 0.999, \quad P(x_{k+1} = P' \mid x_k = P) = 0.001$$

$$P(x_{k+1} = P' \mid x_k = P') = 1$$

---

$$y_k \sim N(R, \sigma(x_k))$$

Θα εκτιμήσουμε την κατάσταση δοσμένων των μετρήσεων  $y_1, \dots, y_k$ .

# Παράδειγμα

Η κατάσταση εξελίσσεται σύμφωνα με τη **στοχαστική δυναμική**

$$P(x_{k+1} = P \mid x_k = P) = 0.999, \quad P(x_{k+1} = P' \mid x_k = P) = 0.001$$

$$P(x_{k+1} = P' \mid x_k = P') = 1$$

---

$$y_k \sim N(R, \sigma(x_k))$$

Θα εκτιμήσουμε την κατάσταση δοσμένων των μετρήσεων  $y_1, \dots, y_k$ . Αρχικά είναι σε κατάσταση  $P$

$$P(x_{k+1} = P \mid y_0, \dots, y_k) = 0.999 P(x_k = P \mid y_0, \dots, y_k)$$

$$P(x_{k+1} = P' \mid y_0, \dots, y_k) = 0.001 P(x_k = P \mid y_0, \dots, y_k) + P(x_k = P' \mid y_0, \dots, y_k)$$



# An Example

Κανόνας Bayes

$$P(x_{k+1} = P \mid y_0, \dots, y_{k+1}) = \frac{P(y_{k+1} \mid x_{k+1} = P) P(x_{k+1} = j \mid y_0, \dots, y_k)}{P(y_{k+1} \mid x_{k+1} = P) P(x_{k+1} = P \mid y_0, \dots, y_k) + P(y_{k+1} \mid x_{k+1} = P') P(x_{k+1} = P' \mid y_0, \dots, y_k)}$$

Ισοδύναμα

$$P(x_{k+1} = P \mid y_0, \dots, y_{k+1}) = \frac{\exp\left(-\frac{(y_k - R)^2}{2\sigma_1^2}\right) P(x_{k+1} = j \mid y_0, \dots, y_k)}{\exp\left(-\frac{(y_k - R)^2}{2\sigma_1^2}\right) P(x_{k+1} = P \mid y_0, \dots, y_k) + \exp\left(-\frac{(y_k - R)^2}{2\sigma_2^2}\right) P(x_{k+1} = P' \mid y_0, \dots, y_k)}$$

Φίλτρα Σωματιδίων

# Εισαγωγή για τα Φίλτρα Σωματιδίων

Μέχρι τώρα υποθέσαμε ότι η

$$p(x_k | y_{0:k})$$

είναι κατά προσέγγιση κανονική.

Είναι πάντα καλή υπόθεση;


# Εισαγωγή για τα Φίλτρα Σωματιδίων

Μέχρι τώρα υποθέσαμε ότι η

$$p(x_k | y_{0:k})$$

είναι κατά προσέγγιση κανονική.

Είναι πάντα καλή υπόθεση;




# Εισαγωγή για τα Φίλτρα Σωματιδίων

Προσέγγιση με άθροισμα Dirac

$$p(x_k | y_{0:k}) \approx \sum_{i=1}^N w_k^i \delta_{x_k^i}(x_k)$$

Είναι **λογική** αυτή η προσέγγιση;



$$F(x) = \int_{-\infty}^x p(z) dz$$


# Εισαγωγή

Προσέγγιση στις σωρευτικές κατανομές


Πόσο καλή είναι η προσέγγιση;

**Απόσταση κατανομών**

- Kullback-Leibler divergence
- **Wasserstein ...**



$$E_{p(x)}[g(X)] \approx E_{q(x)}[g(X)] = \sum_{i=1}^N W^i g(x^i)$$




# Προσέγγιση Κατανομής με Δειγματοληψία

Για την κατανομή  $p(x)$

$$p(x) \approx \sum_{i=1}^N \delta_{x^i}(x)$$

με  $x^i$  δείγματα μιας τ.μ. με κατανομή  $p(x)$

$$E_{p(x)}[g(X)] \approx \frac{1}{N} \sum_{i=1}^N g(x^i)$$



# Διατύπωση

Σύστημα

$$x_{k+1} = f(x_k, w_k)$$

$$y_k = h(x_k, v_k)$$

- Δεν υποθέτουμε τίποτα για τις κατανομές ή τις συναρτήσεις εκτός από ότι
- Ξέρουμε τις κατανομές



# Βήμα Πρόβλεψης

Ξεκινάμε με

$$p(x_k \mid y_{0:k}) \approx \sum_{i=1}^N W_k^i \delta_{x_k^i}(x_k)$$

Κάθε όρος θα λέγεται **σωματίδιο (particle)**

# Βήμα Πρόβλεψης

Ξεκινάμε με

$$p(x_k | y_{0:k}) \simeq \sum_{i=1}^N w_k^i \delta_{x_k^i}(x_k)$$

Κάθε όρος θα λέγεται **σωματίδιο (particle)**

Βήμα πρόβλεψης

Για κάθε particle δειγματοληπτούμε το  $w_k$  με μια τιμή  $w_k^i$  και παράγουμε ένα νέο particle

$$x_{k+1}^{i,-} = f(x_k^i, w_k^i)$$

Η κατανομή του  $x_{k+1}$  με πληροφορία μέχρι **τη στιγμή  $k$** , δίνεται προσεγγιστικά από

$$p(x_{k+1} | y_{0:k}) \simeq \sum_{i=1}^N w_k^i \delta_{x_{k+1}^{i,-}}(x_{k+1})$$

# Βήμα Διόρθωσης

Εκ των προτέρων

$$p(x_{k+1} | y_{0:k}) \approx \sum_{i=1}^N W_k^i \delta_{x_{k+1}^i}(x_{k+1})$$

$$P(x_{k+1} = x_{k+1}^{i,-}) = W_k^i$$

- Εκ των υστέρων πριν την κανονικοποίηση

$$\tilde{W}_{k+1}^i = W_k^i P(y_{k+1} | x_{k+1}^{i,-})$$

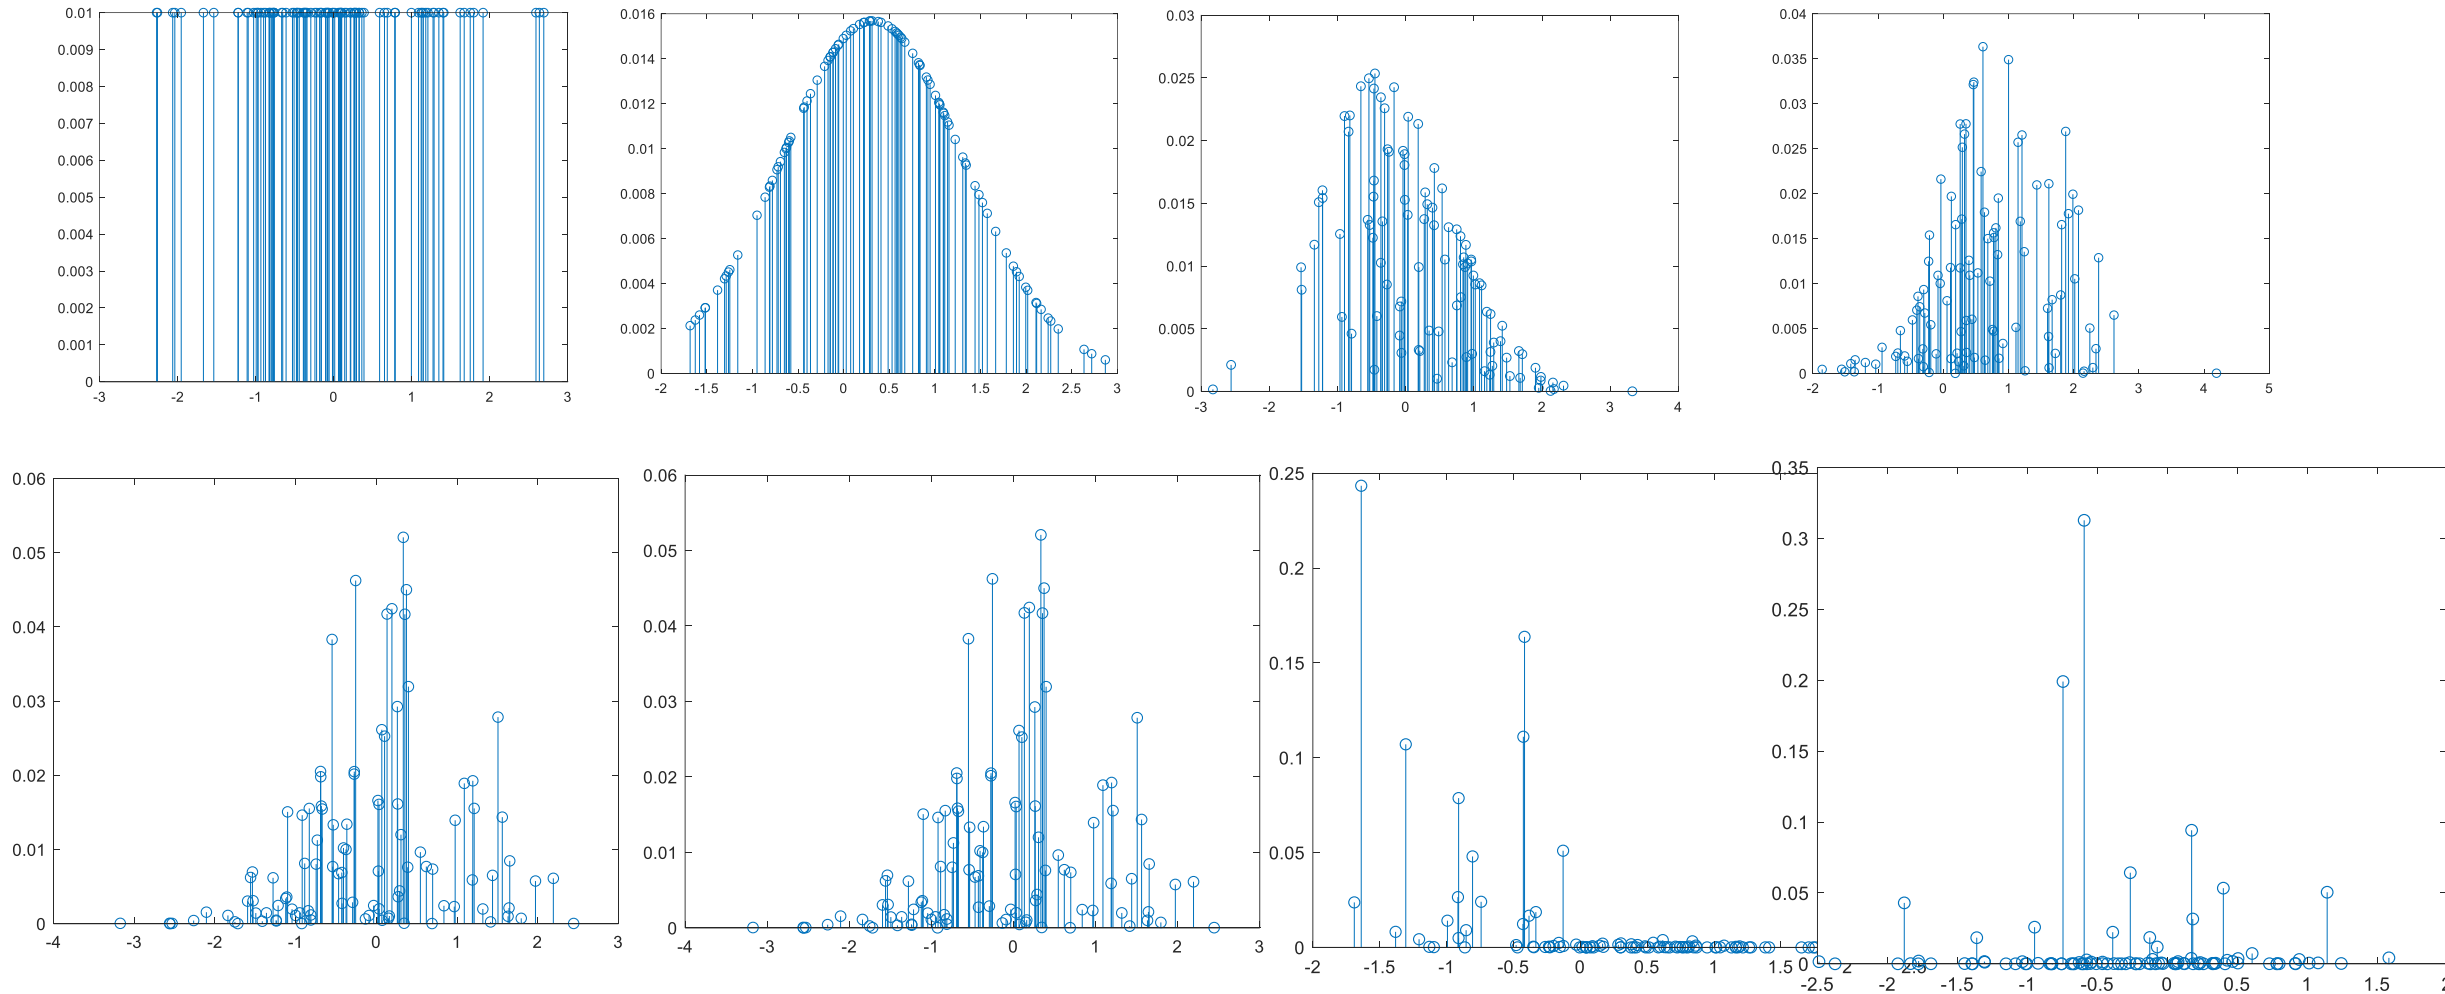
- Κανονικοποίηση

$$W_{k+1}^i = \frac{\tilde{W}_{k+1}^i}{\sum_{i=1}^N \tilde{W}_{k+1}^i}$$



# Importance Sampling

Ένας άλλος τρόπος να δούμε τις ίδιες εξισώσεις είναι η προσπάθεια δειγματοληψίας από την  $p(x_{k+1} | y_{0:k+1})$


# Degeneration Problem



# Degeneration Problem



...



Το βάρος συγκεντρώνεται όλο και περισσότερο σε ένα particle

- Πώς θα προσεγγίσουμε κατανομές;

# Resampling (Επανα-δειγματοληψία)

## **Πρόβλημα:** Degeneracy

- Όλα τα βάρη προσεγγίζουν το 0 εκτός από ένα
- Δεν προσεγγίζουμε καλά την κατανομή
- Σπαταλάμε πόρους

# Resampling (Επανα-δειγματοληψία)

## Πρόβλημα: Degeneracy


- Όλα τα βάρη προσεγγίζουν το 0 εκτός από ένα
- Δεν προσεγγίζουμε καλά την κατανομή
- Σπαταλάμε πόρους

## Resampling

- Ξεκινάμε με τα δείγματα

$$\left(x_{k+1}^i, W_{k+1}^i\right)_{i=1}^N$$

και παράγουμε ομοιόμορφα N particles  
με ίσα βάρη






# Particle Filter Αλγόριθμος

- Αρχικοποιούμε ένα σύνολο Particles

$$(x_{-1}^i, W_{-1}^i), i = 1, \dots, N$$


- 
- Βήμα Πρόβλεψης
  - Βήμα διόρθωσης
  - Resampling

# Example from MATLAB

Pose estimation for a robot with lidar sensor

See video

[https://www.youtube.com/watch?v=NrzmH\\_yerBU](https://www.youtube.com/watch?v=NrzmH_yerBU)



# Importance Sampling

Αρχική ιδέα για Particle Filters: **Importance Sampling**

Αν δεν μπορούμε να δειγματοληπτήσουμε από την κατανομή  $p(x)$ ?

Ας υποθέσουμε ότι μπορούμε να δειγματοληπτούμε από την  $q(x)$

$$\begin{aligned} E_p[g(x)] &= \int g(x) p(x) dx = \int g(x) \frac{p(x)}{q(x)} q(x) dx = \int \tilde{g}(x) q(x) dx = E_q[\tilde{g}(x)] \\ &\simeq \sum_{i=1}^N g(x^i) \frac{p(x^i)}{q(x^i)} = \sum_{i=1}^N w^i g(x^i) \end{aligned}$$

$x^i$  ακολουθεί την  $q(x)$

# Importance Sampling

$p(x)$  προσεγγίζεται από

$$\sum_{k=1}^N w^i x^i$$
$$x^i \sim q(x), \quad w^i = \frac{p(x^i)}{q(x^i)}$$

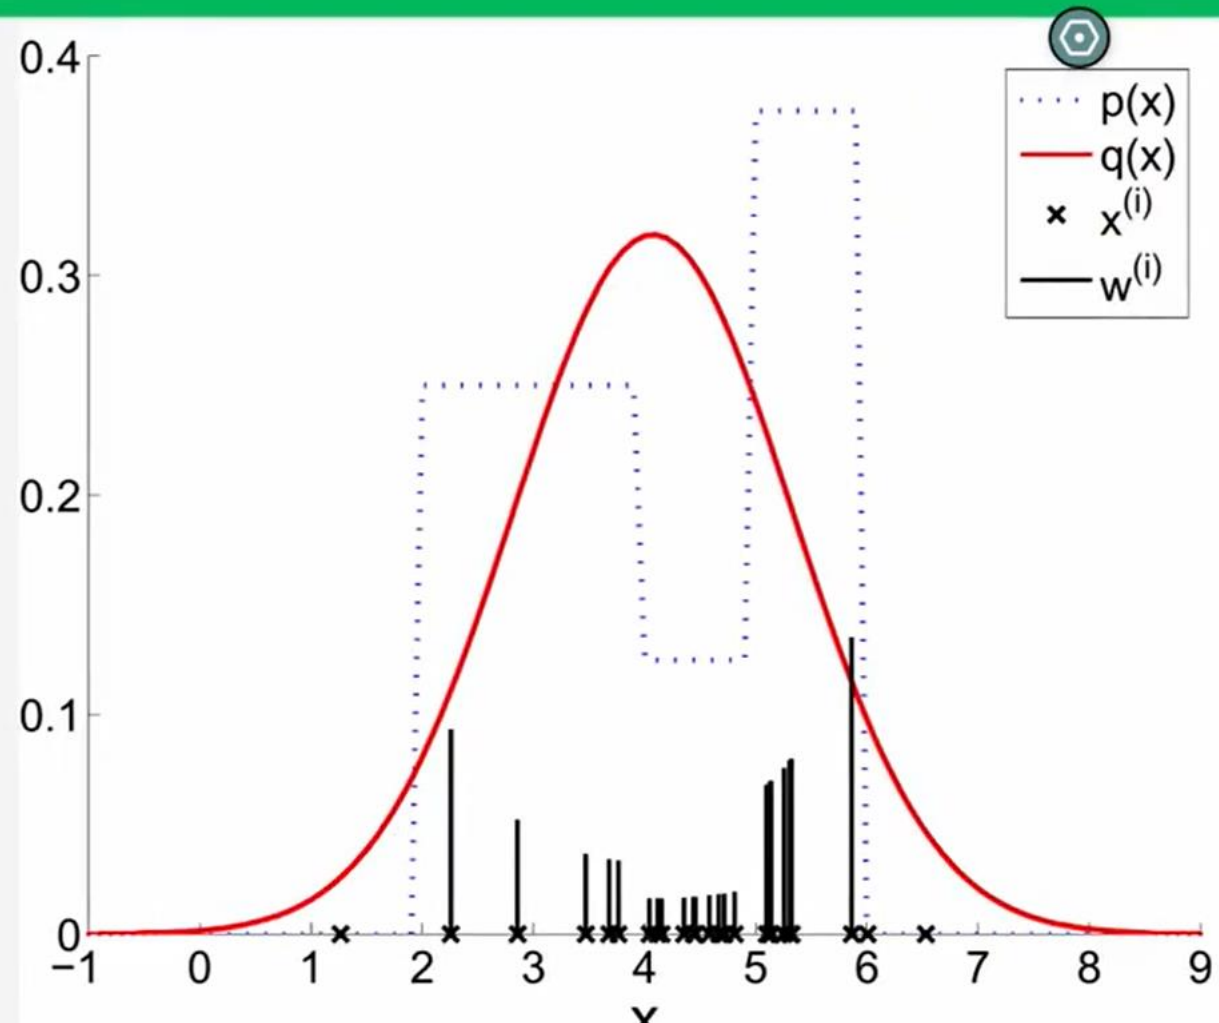
Η μέση τιμή είναι η ίδια, αλλά, η διακύμανση εξαρτάται από την  $q$ . Βέλτιστο για  $q = p$

# Παράδειγμα

## Example – Importance sampling

- Approximate  $p(x)$  using  $N$  independent samples from  $q(x) = \mathcal{N}(x; 4, 1.5^2)$ .

Figure from  
[7.2 Monte Carlo approximations and Importance sampling - YouTube](#)



# Επεκτάσεις

- Πότε και πώς γίνεται η δειγματοληψία πιθανόν με χρήση Importance Sampling
- Πότε και πώς γίνεται η επανάδειγματοληψία
- Χρήση μιας proposal distribution
- Rao-Blackwellized PF